TRANSCRIPCIÓN TEXTUAL COMPLETA + DESGLOSE DE DIAGRAMAS • MATERIAL DE CÁTEDRA

Redes Neuronales: Transcripción Íntegra de Teoría y Diapositivas

1. Introducción: ¿Qué son, Por qué y Cuándo usarlas?

DIAPOSITIVAS 1 A 5

TRANSCRIPCIÓN TEXTUAL: REDES NEURONALES

> **«Redes Neuronales»**
>
> «Los modelos más complejos y **poderosos**.
>
> Idea vieja, pero resucitada por disponibilidad de datos y hardware.
>
> Para aprendizaje supervisado, no supervisado, y por refuerzo. Datos estructurados y no estructurados. E incluso generación de texto, imágenes, etc. Un mundo de posibilidades...
>
> ... Nosotros nos vamos a centrar en aprendizaje **supervisado** (clasificación y regresión).»

TRANSCRIPCIÓN TEXTUAL: ¿POR QUÉ? ¿CUÁNDO?

> **«Por qué? Cuándo?»**
>
> - «Cuando modelos simples no funcionan...»
> - «... y tenemos hardware y datos.»
> - «Cuando trabajamos con imágenes, video, audio y más.»
> - «Cuando alguien ya entrenó y publicó una red que hace lo que queremos, o muy parecido.»

2. Repaso: Descenso por el Gradiente y Regresión Logística

DIAPOSITIVAS 6 A 17

TRANSCRIPCIÓN TEXTUAL: REPASO Y LÍMITES LINEALES

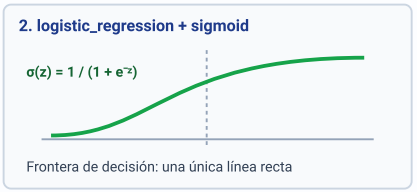
> • **«Repasemos: descenso por el gradiente»** *(Ver diagramas: `train.svg` y `gradient_descent.svg`).*
>
> • **«Repasemos: regresión logistica»** *(Ver diagramas: `logistic_regression_function.svg`, `sigmoid_function.png`, `logistic_regression_boundary_good_1.svg` y `_2.svg`).*
>
> • **«Funciona siempre?»** *(Ver diagrama: `non_linear_clasification.svg`).*

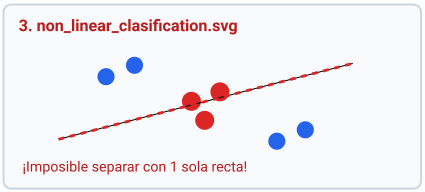
TRANSCRIPCIÓN TEXTUAL: NO LINEALIDAD

> **«No linealidad»**
>
> «Necesitamos un modelo más complejo, una recta **nunca funcionaría**.
>
> Veamos entonces, **redes neuronales**.»

Contenido de las imágenes de esta sección: Muestran el ciclo iterativo de entrenamiento minimizando el error mediante la pendiente (gradiente), la fórmula lineal pasada por la curva Sigmoidea en forma de "S" entre 0 y 1, cómo una recta separa bien clases linealmente separables, y cómo fracasa cuando una clase rodea o se intercala de forma curva con otra.







Reconstrucción Visual (Diapositivas 7 a 15): (1) Optimización por descenso del gradiente; (2) Función sigmoidea y separación lineal en regresión logística; (3) Dataset no lineal donde una sola recta falla inevitablemente.

3. La Neurona Artificial y el Paso a una Red Neuronal

DIAPOSITIVAS 18 A 32

TRANSCRIPCIÓN TEXTUAL: NEURONA

> **«Neurona»**
> - «Vagamente inspirada en neuronas reales.»
> - «N entradas, 1 salida»
> - «La salida sale de hacer una operación con las entradas y pesos internos.»
> - «... O sea que es una **función**!»
>
> *(Imagen: `images/neuron_2.svg`)*

TRANSCRIPCIÓN TEXTUAL: ACT == SIGMOID

> **«Qué pasa si Act == Sigmoid?...»**
>
> «Es una **regresión logística**! Podemos entrenarla con **descenso por el gradiente**, para que clasifique cosas.
>
> Una neurona sola, ya podría ser entrenada y clasificar... cosas lineales.»

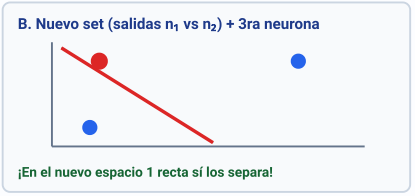
4. Construcción Paso a Paso de la Red (3 Neuronas)

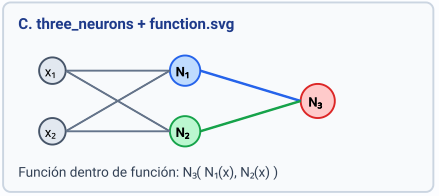
SECUENCIA VISUAL COMPLETA

TRANSCRIPCIÓN TEXTUAL: ¿Y UNA RED NEURONAL? (DIAPOSITIVAS 23 A 32)

> • **«Y una red neuronal?»** → «Muchas neuronas juntas podrán hacer algo mejor?»
>
> • *Secuencia de imágenes e interrogantes exactos de la presentación:*
>
> 1. `images/non_linear_clasification.svg` (Problema original no separable por una recta).
> 2. `images/non_linear_clasification_two_neurons.svg` (Dos neuronas trazando dos rectas distintas sobre el mismo espacio).
> 3. **«Y si armamos ahora otro set de datos, con las salidas de estas dos neuronas y su clase?»** → `images/non_linear_clasification_outputs_two_neurons.svg`.
> 4. **«Y si intentamos ahora usar ese nuevo set de datos, para entrenar una tercer neurona?»** → `images/non_linear_clasification_third_neuron.svg`.
> 5. Conexión final de las 3 neuronas y su ecuación compuesta: `images/three_neurons.svg` y `images/three_neurons_function.svg`.







Reconstrucción Visual (Diapositivas 26 a 32): Dos neuronas generan nuevas coordenadas intermedias donde una tercera neurona logra separar las clases linealmente. Al unirlas, forman una función compuesta (red neuronal).

TRANSCRIPCIÓN TEXTUAL: RED NEURONAL Y MLP (DIAPOSITIVAS 33 A 35)

> **«Red neuronal!»** *(Imagen: `images/neural_network_1.svg`)*
>
> «Este es **un tipo** de red neuronal específico: Multi-Layer Perceptron, o **MLP**.
> Es una red "feed forward": las operaciones se hacen en una sola dirección, hacia adelante.»
>
> - «Podemos agregar muchas capas, con muchas neuronas en cada capa.»
> - «Hay una **capa de entrada** y una **capa de salida**. Las demás son **capas ocultas**.»
> - «Se suele dibujar a las entradas como neuronas también, aunque no lo sean realmente.»
> - «Es demostrable que una sola capa oculta es suficiente para poder lograr cualquier función. El tema es cuántas neuronas, y qué tan fácil aprende eso.»
> - «Podemos tener muchas salidas si ponemos varias neuronas en la capa de salida!»

5. Conocimiento, Pesos, Derivadas y Backpropagation

DIAPOSITIVAS 36 A 41

TRANSCRIPCIÓN TEXTUAL: CONOCIMIENTO Y PESOS

> **«Dónde está el conocimiento?»** *(Imagen: `images/neural_network_2.svg` — señala los pesos en las flechas/conexiones de la red).*
>
> **«Cómo encontramos esos pesos?»**
> «Nuestro viejo amigo, **descenso por el gradiente**. Aunque también hay otras opciones (como algoritmos genéticos).»
>
> **«Y las derivadas de esto?????»**
> «Se puede. Es complejo. Por suerte las herramientas nos las resuelven.
> ... pero hay un problema: **¿Cómo determinar la actualización de pesos de capas ocultas?**»

TRANSCRIPCIÓN TEXTUAL: BACKPROPAGATION

> **«Backpropagation»** *(Imagen: `images/backpropagation.gif`)*
>
> «Es un algoritmo que permite propagar la señal de error a las capas ocultas.
>
> Por ejemplo, un peso del final se modifica sin problemas. Un peso del inicio se modifica **teniendo en cuenta cómo se propaga el error del final a las salidas de esta capa**.
>
> No vamos a ver su detalle matemático. Las herramientas lo traen implementado.»

6. Decisiones de Arquitectura e Hiperparámetros

DIAPOSITIVAS 42 A 52

Diapositiva / Pregunta Textual	Transcripción Exacta del Contenido
«Hay que decidir unas cuantas cosas» *(Arquitectura y Neural Network Zoo)*	«Cuántas **capas**? Cuántas **neuronas** en cada capa? Cómo son las **conexiones** entre capas? Esto se llama "Arquitectura" de nuestra red.» *(Imagen: `images/zoo.png`).* «Muy buen resumen de la utilidad de cada arquitectura!: **THE NEURAL NETWORK ZOO** (`http://www.asimovinstitute.org/neural-network-zoo/`). Nosotros vamos a ver solo dos de ellas, el MLP (las que vimos recién) y las Convolucionales (la clase que viene).»
«Cuál usamos entonces?»	«Pregunta difícil de responder: depende del caso, mirar cosas que hizo otra gente, buscar, etc. Pero: • **Pocas neuronas?** Podemos no lograr buen resultado. • **Muchas neuronas?** Podemos sobreentrenar, y puede ser muy lento.»
«Qué función de activación en cada capa?»	«Paras la mayoría lo habitual es: • **Relu, Tanh o Sigmoidea** en capas intermedias. • **Sigmoidea** en capa de salida de redes con una sola salida entre 0 y 1. • **Softmax** en capa de salida de redes con N salidas entre 0 y 1.»
«Qué variante de decenso por el gradiente?»	«Normalmente **"adam"** anda bien.»
«Qué variante de función de error?»	«Lo habitual es: • **Binary_crossentropy** para redes con una sola salida entre 0 y 1. • **Categorical_crossentropy** para redes con N salidas entre 0 y 1. A veces puede hacer falta configurar "pesos" para los errores positivos y negativos.»

7. Consejos Finales y Técnica Relacionada: Dropout

DIAPOSITIVAS 53 Y 54

TRANSCRIPCIÓN TEXTUAL: Y ALGUNOS CONSEJOS MÁS

> **«Y algunos consejos más»**
>
> - «Normalizar las entradas.»
> - «Como siempre, entrenar y testear con sets separados. Las redes neuronales pueden overfitear muy fácil!»
> - «Probar cambios de a **pocas** cosas a la vez.»

TRANSCRIPCIÓN TEXTUAL: TÉCNICA ÚTIL: DROPOUT

> **«Técnica relacionada útil: dropout»** *(Imagen: `images/dropout.svg`)*
>
> «Capa que "apaga" conexiónes de forma aleatoria.
>
> **Para qué?**
>
> Para evitar que cada capa se "memorice" resultados que tiene que dar para determinados inputs (overfit interno y de la red en general).»